ESPRIT School of Business

Licence 3 — Business Computing BI

Projet Intégré

Analyse et Prédiction du Churn Client

Projet Intégré — Analyse et Prédiction du Churn Client

Tuteurs du projet

Aymen Ben Brik et Hela Hammami

2026

Table des matières

1. Contexte **2**

2. Objectifs pédagogiques **2**

3. Périmètre fonctionnel **2**

3.1 Phase 1 — Collecte et compréhension des données 3
3.2 Phase 2 — Conception du DWH et ETL 3
3.3 Phase 3 — Reporting et dashboard 3
3.4 Phase 4 — Modèles prédictifs 3
3.5 Phase 5 — Déploiement 3

4. Livrables attendus **3**

5. Modalités **4**

6. Critères d'évaluation **4**

7. Règles importantes **5**

1. Contexte

Un établissement financier met à votre disposition un jeu de données anonymisé et généralisé décrivant des clients, leurs comptes et leurs produits. La fidélisation client (lutte contre l'attrition, ou *churn*) est un enjeu majeur du secteur : acquérir un nouveau client coûte plusieurs fois plus cher que d'en conserver un existant.

Votre mission est de concevoir, de bout en bout, une **solution décisionnelle complète** permettant de comprendre, mesurer et anticiper le churn, puis de mettre ces analyses à disposition des décideurs métier via une interface web.

2. Objectifs pédagogiques

Ce projet vous permet de mettre en pratique l'ensemble de la chaîne décisionnelle :

- Comprendre et qualifier des données (analyse univariée, valeurs manquantes, outliers).
- Concevoir un entrepôt de données et ses flux d'alimentation (modélisation dimensionnelle, ETL).
- Produire des indicateurs métier et des tableaux de bord avec Power BI et DAX.
- Modéliser l'évolution d'un KPI dans le temps (série temporelle, Deep Learning) et prédire le churn (Machine Learning).
- Concevoir et livrer une interface web documentée par des diagrammes UML.
- Travailler en équipe avec une démarche projet structurée (versioning, livrables, présentation).

3. Périmètre fonctionnel

Le projet est structuré en **cinq phases successives**. Chaque phase comporte un socle **obligatoire** et des **bonus** optionnels. Traitez toujours le socle obligatoire avant d'aborder un bonus.

Phase	Intitulé	Échéance	Obligatoire	Bonus
1	Collecte et compréhension des données	Semaine du 9/11	Analyse univariée ; décompte des outliers et des valeurs manquantes	Web scraping (Beautiful Soup, Playwright, Scrapy) ; analyse bivariée
2	Conception du DWH et ETL	Semaine du 16/11	Talend + PostgreSQL administré avec pgAdmin	SSIS ; Databricks (bronze / silver / gold) ; SCD de type 2 ; Python
3	Reporting et dashboard	23/11	Power BI ; DAX pour les KPI	Visualisation avec Databricks ; interface JavaScript
4	Modèles prédictifs	1/12	Fixer un KPI ; analyse de sa série temporelle ; modèle de série temporelle en Deep Learning (LSTM / RNN) ; Machine Learning pour le churn	Traiter plusieurs KPI
5	Déploiement	7/12	Interface web ; diagrammes UML : cas d'utilisation global, une séquence, classes	DevOps : tests ; application mobile

3.1 Phase 1 — Collecte et compréhension des données

— Charger les fichiers fournis et vérifier leur intégrité.
— Réaliser l'**analyse univariée** de chaque variable utile (distribution, tendance centrale, dispersion, modalités).
— Produire le **décompte des valeurs manquantes** et le **décompte des outliers** par variable, en précisant la méthode retenue (IQR, z-score, etc.).
— *Bonus* : enrichir le contexte par **web scraping** ; réaliser une **analyse bivariée**.

3.2 Phase 2 — Conception du DWH et ETL

— Concevoir un modèle dimensionnel en étoile (faits + dimensions) et justifier le grain.
— Implémenter les flux d'alimentation avec **Talend**.
— Créer et administrer l'entrepôt sous **PostgreSQL** avec **pgAdmin**.
— *Bonus* : version **SSIS** ; architecture **Databricks** en médaillon (bronze / silver / gold) ; historisation **SCD de type 2** ; traitements en **Python**.

3.3 Phase 3 — Reporting et dashboard

— Produire un rapport **Power BI** connecté à l'entrepôt.
— Écrire les KPI en **DAX** et permettre une exploration interactive (filtres, drill-down).
— Au minimum : vue d'ensemble, analyse du churn, segmentation client.
— *Bonus* : visualisation avec **Databricks** ; restitution dans une **interface JavaScript**.

3.4 Phase 4 — Modèles prédictifs

— **Fixer un KPI** et justifier son intérêt métier (exemple : nombre hebdomadaire de clôtures de comptes).
— Analyser sa **série temporelle** : tendance, saisonnalité, ruptures, pics.
— Construire un modèle de série temporelle en **Deep Learning (LSTM ou RNN)**, comparé à une référence simple.
— Construire un modèle de **Machine Learning** de prédiction du churn et l'évaluer avec des métriques adaptées.
— *Bonus* : appliquer la démarche à **plusieurs KPI**.

3.5 Phase 5 — Déploiement

— Développer une **interface web** exposant les prédictions et les indicateurs de synthèse.
— Livrer trois **diagrammes UML** : cas d'utilisation **global**, **une seule** séquence, classes.
— *Bonus* : démarche **DevOps** avec tests automatisés ; **application mobile**.

4. Livrables attendus

Trois livrables sont attendus à la fin du projet, en plus du rendu de chaque phase :

Livrable	Format	Contenu attendu
Code source	Dépôt GitHub, sans aucune donnée	Notebooks, jobs Talend exportés, scripts SQL, mesures DAX, code ML, application web, diagrammes UML, README détaillé, instructions d'installation et d'exécution
Présentation orale	Slides (PPT/PDF), 20 min + 10 min de questions	Démonstration de l'application, présentation de la démarche, principaux résultats
Rapport	PDF, 25–40 pages	Document professionnel décrivant la démarche, l'architecture, les choix techniques, les résultats, les limites et les perspectives

5. Modalités

— **Composition des équipes** : 3 à 4 étudiants par groupe.
— **Durée** : cinq jalons, de la semaine du 9/11 au 7/12/2026, à temps partagé avec les autres cours.
— **Encadrement** : un point d'avancement à chaque jalon avec les tuteurs.
— **Outils** : les outils marqués *obligatoire* sont imposés. Les autres restent libres dans le respect du guide étudiant (document 4).

6. Critères d'évaluation

Critère	Pondération
Compréhension des données (analyse univariée, manquants, outliers)	10 %
Qualité du DWH et de l'ETL (Talend, PostgreSQL)	20 %
Pertinence du reporting (Power BI, DAX)	15 %
Rigueur des modèles prédictifs (série temporelle, churn)	25 %
Interface web et diagrammes UML	15 %
Qualité du code, du rapport et de la présentation orale	15 %

Les **bonus** sont évalués en plus du socle et ne compensent pas une partie obligatoire absente.

7. Règles importantes

— **Confidentialité** : les données sont confidentielles et remises hors de GitHub. Aucune donnée, même partielle ou agrégée à la ligne, ne doit être publiée (dépôt, application, capture d'écran, modèle embarquant des lignes). Seul le code peut être partagé.
— **Non-réidentification** : toute tentative d'identifier l'établissement, une agence ou un client est **interdite**, y compris par recoupement ou web scraping. Si vous pensez reconnaître l'une de ces informations, n'en parlez pas dans vos livrables et prévenez immédiatement les tuteurs.
— **Anonymat** : ne formulez aucune hypothèse sur l'origine des données, ni dans le code, ni dans le rapport, ni dans la présentation.
— **Application publique** : l'interface déployée n'affiche que des agrégats et des profils fictifs. Toute liste de clients reste derrière une authentification et n'est jamais incluse dans le dépôt.
— **Versioning** : le dépôt GitHub doit montrer un historique régulier de commits par chaque membre de l'équipe.
— **Reproductibilité** : tout doit pouvoir être ré-exécuté par un tiers à partir du README.