ESPRIT School of Business

Licence 3 — Business Computing BI

Projet Intégré

Analyse et Prédiction du Churn Client

Description des Données

Tuteurs du projet

Aymen Ben Brik et Hela Hammami

2026

Table des matières

1. Vue d'ensemble **2**

2. Fichier principal — Description des colonnes **2**
2.1 Identifiants . . . 2
2.2 Informations client . . . 2
2.3 Informations compte . . . 3
2.4 Informations produit . . . 3

3. Fichiers de référence **4**

4. Définition de la variable cible (churn) **4**

5. Variables pour la prédiction **4**
5.1 Attention à la fuite de cible . . . 4
5.2 Pistes de variables . . . 5

6. Séries temporelles — points d'attention **5**

7. Qualité des données **5**

8. Précautions **5**

Les données mises à votre disposition sont issues d'un système d'information bancaire. Elles ont été **anonymisées et généralisées** : identifiants aléatoires, libellés neutres, regroupements, dates et montants arrondis. Elles conservent leur cohérence d'ensemble, mais ne décrivent plus aucune personne ni aucun site de façon exploitable.

> **À retenir** : les dates ont été volontairement **décalées** et les montants **arrondis et plafonnés**. Ils ne doivent pas être rapprochés d'un calendrier ou d'une source externe. Raisonnez sur des durées, des évolutions et des ordres de grandeur.

1. Vue d'ensemble

Le jeu de données est composé de :

- **1 fichier principal** `data_churn.csv` (~75 Mo, 483 536 lignes, 32 colonnes) ;
- **5 fichiers de référence** au format Excel (`.xlsx`) qui donnent le libellé associé aux codes du fichier principal.

Il décrit 363 024 clients et 410 309 comptes. Une ligne correspond à un **rapprochement client / compte / produit** : un client ou un compte peut donc apparaître plusieurs fois, et environ 9 % des lignes correspondent à des clients sans compte renseigné. Définissez clairement votre grain avant tout calcul.

Pour les plus gros clients, le nombre de lignes a été plafonné à 100. **Les totaux ne représentent donc pas un encours réel** : utilisez-les pour comparer, pas comme des montants absolus.

2. Fichier principal — Description des colonnes

2.1 Identifiants

Colonne	Type	Description
`CUSTOMER_NO`	Code (`K...`)	Identifiant aléatoire du client
`ACCOUNT_NO`	Code (`X...`)	Identifiant aléatoire du compte
`BRANCH_GROUP`	Code (`AG01` à `AG20`)	Regroupement anonyme d'agences, sans signification géographique. `AG00` = masqué

2.2 Informations client

Colonne	Type	Description
`NATIONALITY_REGION`	Texte	Zone de nationalité : `LOCAL`, `EUROPE`, `AFRIQUE_MO`, `AMERIQUES`, `ASIE_OCEANIE`, `AUTRE`
`RESIDENCE_REGION`	Texte	Zone de résidence (mêmes modalités)
`MARITAL_STATUS`	Code	Statut marital (C = célibataire, M = marié(e), D = divorcé(e), V = veuf/veuve)
`BIRTH_PERIOD`	Année	Début de la tranche de naissance de 5 ans (`1980` = 1980–1984). Dernière tranche basse : `1935` et avant

Colonne	Type	Description
`CUST_OPENING_DATE`	Date (YYYYMMDD)	Entrée en relation : début de trimestre, d'année ou de période de 5 ans selon le client
`NATURE_CLIENT`	Code	Type de client : `PPH` (personne physique), `PM` (personne morale), `PRO` (professionnel), `TRPP` et `TRPM` (autres catégories)
`PARTYCLASS`	Texte	Classe commerciale : `Retail`, `Premium`, `Corporate Small`, `Corporate`
`LOB`	Code	Ligne métier (FK vers `TARGET.xlsx`)
`SCORE_KYC`	Code	Score de connaissance client (Know Your Customer)
`COMPLETED_FILE`	YES / vide	Dossier client complet
`LAST_REVIEW_DATE`	Date (YYYYMMDD)	Dernière revue du dossier, ramenée au mois
`NEXT__REVIEW_DATE`	Date (YYYYMMDD)	Prochaine revue prévue, ramenée au mois
`INDUSTRY`	Code (A à Z)	Section d'activité (FK vers `INDUSTRY.xlsx`)
`SALARY`	Numérique	Revenu déclaré, arrondi à 1 chiffre significatif et plafonné

2.3 Informations compte

Colonne	Type	Description
`ACCOUNT_STATUS`	Texte	`Active` ou `Closed` — **base de la variable cible**
`ACCT_OPENING_DATE`	Date (YYYYMMDD)	Ouverture du compte, ramenée au lundi de la semaine
`ACCT_CLOSE_DATE`	Date (YYYYMMDD)	Clôture du compte, ramenée au lundi de la semaine
`ACCOUNT_CATEGORY`	Code (`CAT...`)	Famille de comptes (FK vers `ACCOUNT_CATEGORY.xlsx`)
`ACCOUNT_TYPE_DESC`	Texte	Libellé de la famille de comptes
`CURRENCY`	Code	Devise (FK vers `CURRENCY.xlsx`)
`CLOSURE_REASON`	Code (`RSN...`)	Motif de clôture (FK vers `CLOSURE_REASON.xlsx`)
`ACCT_BALANCE`	Numérique	Solde arrondi à 2 chiffres significatifs et plafonné

2.4 Informations produit

Colonne	Type	Description
`PRODUCT_GROUP`	Texte	Groupe de produits générique
`PRODUCT_LINE`	Texte	Ligne de produits
`STARTDATE`	Date (YYYYMMDD)	Début du produit, ramené au mois

Colonne	Type	Description
`MATURITYDATE`	Date (YYYYMMDD)	Échéance, ramenée au mois
`AMOUNT`	Numérique	Montant du produit, arrondi à 2 chiffres significatifs et plafonné
`FIXEDRATE`	Numérique	Taux fixe, arrondi au demi-point
`PRODUCT_STATUS`	Texte	Statut du produit

3. Fichiers de référence

Fichier	Clé	Contenu
`ACCOUNT_CATEGORY.xlsx`	`CATEGORY_ID`	Familles de comptes
`CLOSURE_REASON.xlsx`	`REASON_ID`	Motifs de clôture
`CURRENCY.xlsx`	`CURRENCY_CODE`	Devises (`LCY` = monnaie locale, `LCC` = monnaie locale convertible)
`INDUSTRY.xlsx`	`INDUSTRY_CODE`	Sections d'activité
`TARGET.xlsx`	`TARGET_CODE`	Lignes métier

Le calendrier n'est pas fourni : il est à construire vous-même.

4. Définition de la variable cible (churn)

Le **churn** se définit ici comme la **clôture d'un compte** :

```
churn = 1  si  ACCOUNT_STATUS = "Closed"
churn = 0  si  ACCOUNT_STATUS = "Active"
ligne exclue si ACCOUNT_STATUS est vide
```

Une définition plus fine est possible (par exemple : churn d'un client = clôture de **tous** ses comptes), à justifier dans le rapport. Le taux dépend fortement du grain : environ **40 %** des lignes, **36 %** des comptes et **32 %** des clients. Le déséquilibre reste donc modéré : vérifiez-le et justifiez toute technique de rééquilibrage.

5. Variables pour la prédiction

5.1 Attention à la fuite de cible

Le fichier est une **photographie** prise après les clôtures : certaines colonnes révèlent le résultat au lieu de le prédire. **À ne pas utiliser comme variables explicatives** :

- `ACCT_CLOSE_DATE` et `CLOSURE_REASON` : renseignées uniquement pour les comptes clos.
- `ACCT_BALANCE` **et sa valeur manquante** : le solde est vide pour environ 68 % des comptes clos et n'est jamais vide pour les comptes actifs. Toute variable dérivée de ce vide trahit la cible.
- La famille de compte, la devise et le montant : leur disponibilité peut suivre le même schéma, à contrôler.
- `PRODUCT_STATUS` : certaines modalités correspondent à la fermeture.

Un score proche de 100 % signale presque toujours une fuite, pas un bon modèle. Le rapport doit présenter ce contrôle.

5.2 Pistes de variables

- **Démographiques** : tranche d'âge, statut marital, zone de nationalité ou de résidence.
- **Ancienneté** : ancienneté du client et du compte, à calculer depuis leurs dates d'ouverture.
- **Comportementales** : nombre de comptes par client, diversité des produits, secteur, segment commercial.
- **Conformité** : score KYC, dossier complet, ancienneté de la dernière revue.

6. Séries temporelles — points d'attention

`ACCT_CLOSE_DATE` et `ACCT_OPENING_DATE` permettent de construire des séries **hebdomadaires**. La granularité mensuelle ne suffit pas : la période de clôtures couvre environ 47 mois, soit trop peu de points pour un LSTM.

- La série des clôtures compte environ **200 semaines**, dont une dizaine sans aucune clôture : ces semaines valent **0** et doivent être ajoutées.
- **Cinq semaines concentrent environ la moitié des clôtures** : ce sont des opérations de masse. Elles doivent être identifiées et traitées (variable d'intervention, série corrigée, modèle robuste), puis ce choix doit être justifié.
- Comptez la série au grain **compte** après déduplication, sinon les lignes multiples la déforment.
- Le découpage entraînement / test doit **respecter l'ordre du temps**. Aucun mélange aléatoire.

7. Qualité des données

Le jeu conserve des défauts à traiter dans vos phases d'analyse et d'ETL :

- **Valeurs manquantes** nombreuses : plus de 85 % sur `MATURITYDATE`, `FIXEDRATE`, `STARTDATE`, `PRODUCT_STATUS` ; environ 70 % sur `SALARY`. Certains vides sont **volontaires** et viennent de l'anonymisation.
- **Doublons** : plusieurs milliers de lignes strictement identiques, et bien plus au grain compte.
- **Dates numériques** au format `YYYYMMDD` à convertir. La précision de `CUST_OPENING_DATE` varie selon les clients.
- **Soldes négatifs** et **montants extrêmes** : environ 32 % des soldes sortent des bornes IQR. Les comptes débiteurs expliquent une partie de ces valeurs, qu'il faut interpréter avant de les exclure.
- **Valeurs plafonnées** : un pic sur la valeur maximale d'un montant vient du plafonnement, pas d'un phénomène métier.

8. Précautions

- **Ne pas publier les données**, sur GitHub ou tout autre service.
- **Ne pas chercher** à identifier l'établissement, une agence ou un client.
- Utiliser un `.gitignore` qui exclut au minimum : `data/`, `*.csv`, `*.xlsx`, `*.pkl`, `*.pbix`.
- Ne pas envoyer les données à un service externe (assistant en ligne, outil de profilage hébergé) sans l'accord des tuteurs.